

Localisation par filtrage de Kalman : du problème unidimensionnel à la navigation par odométrie

Fatimetou Narjah

Mohamed Benloughmari

Introduction

Le filtre de Kalman estime l'état d'un système dynamique en fusionnant un modèle d'évolution avec des mesures bruitées. Ce rapport en étudie l'application à la localisation, en progressant du cas unidimensionnel (position–vitesse) jusqu'à la navigation d'un robot par odométrie. On y examine le comportement du filtre linéaire, puis du filtre étendu (EKF) face à des mesures non linéaires, avant d'analyser l'effet des trous de mesure, des défaillances capteur et du réglage des covariances Q et R .

1 Q0a — Filtre de Kalman linéaire

On note l'état $x = [p \ v]^\top$ (position, vitesse).

On construit le modèle d'évolution suivant

$$x_{k+1} = F x_k + w_k, \quad F = \begin{bmatrix} 1 & \Delta T \\ 0 & 1 \end{bmatrix}, \quad w_k \sim \mathcal{N}(0, Q), \quad Q = \begin{bmatrix} 1 & 0 \\ 0 & 0.001 \end{bmatrix} \quad (1)$$

avec $\Delta T = 1$.

On a le modèle d'observation suivant, où l'on mesure la position seule

$$y_k = H x_k + v_k, \quad H = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad v_k \sim \mathcal{N}(0, R), \quad R = [1] \quad (2)$$

Le problème est initialisé comme suit : réel $x_0 = [20, 12]^\top$, estimation $\hat{x}_0 = [0, 10]^\top$, covariance $P_0 = \text{diag}(100, 1)$.

1.1 Récapitulatif des équations (rappel)

$$\begin{aligned} \text{Prédiction : } \quad & \hat{x}_{k|k-1} = F \hat{x}_{k-1}, & P_{k|k-1} &= F P_{k-1} F^\top + Q \\ \text{Innovation : } \quad & \nu_k = y_k - H \hat{x}_{k|k-1}, & S_k &= H P_{k|k-1} H^\top + R \\ \text{Gain : } \quad & K_k = P_{k|k-1} H^\top S_k^{-1} \\ \text{Correction : } \quad & \hat{x}_k = \hat{x}_{k|k-1} + K_k \nu_k, & P_k &= (I - K_k H) P_{k|k-1} \end{aligned} \quad (3)$$

La figure 1 montre que l'estimation de la position converge rapidement vers la position réelle, malgré un écart initial important. La vitesse n'étant pas directement observée, elle est estimée indirectement à partir de l'évolution temporelle des mesures de position. L'incertitude sur la vitesse reste ainsi plus importante que celle sur la position, notamment au début, avant de diminuer progressivement. Le filtre parvient néanmoins à reconstruire correctement la vitesse et à faire converger l'ensemble de l'état vers la trajectoire réelle.




Figure 1: Estimation de la position et de la vitesse (Q0a).

2 Q0b — Filtre de Kalman étendu

Après avoir étudié le cas linéaire, on quitte désormais ce cadre : on considère un objet qui se déplace sur l'axe x , d'état $x = [s \ v]^\top$ (position, vitesse), mais dont la mesure n'est plus linéaire. En effet, un capteur placé en $(x_s, y_s) = (0, -20)$ mesure un angle bruité vers l'objet, et non plus la position, sans aucune mesure de distance. C'est pourquoi on a recours au filtre de Kalman étendu (EKF), qui linéarise localement le modèle d'observation.

Modèle d'évolution. Tout d'abord, l'évolution reste linéaire ($\Delta T = 1$) :

$$x_{k+1} = Fx_k + w_k, \quad F = \begin{bmatrix} 1 & \Delta T \\ 0 & 1 \end{bmatrix}, \quad w_k \sim \mathcal{N}(0, Q), \quad Q = \begin{bmatrix} 0.0001 & 0 \\ 0 & 0.01 \end{bmatrix} \quad (4)$$

Modèle d'observation. Ensuite, l'observation devient non linéaire :

$$z_k = h(s_k) + v_k, \quad h(s) = \text{atan2}(-y_s, s - x_s) = \text{atan2}(20, s), \quad v_k \sim \mathcal{N}(0, R), \quad (5)$$

avec $R = (1^\circ \text{ en radians})^2 \approx (0.01745)^2 \approx 3.05 \times 10^{-4}$.

Jacobienne d'observation. L'EKF linéarise h autour de l'état courant :

$$H = \frac{\partial h}{\partial x} = \begin{bmatrix} \frac{\partial h}{\partial s} & \frac{\partial h}{\partial v} \end{bmatrix} = [h_s \ 0], \quad h_s = \frac{y_s}{(s - x_s)^2 + y_s^2} = \frac{-20}{s^2 + 400} \quad (6)$$

Un point essentiel apparaît ici : h_s dépend de s et tend vers 0 quand l'objet s'éloigne du capteur ($s \rightarrow \infty$). Autrement dit, la mesure devient de moins en moins informative sur la position.

Initialisation. Enfin, le problème est initialisé avec le réel $x_0 = [2, 4]^\top$, l'estimation $\hat{x}_0 = [0, 5]^\top$ et $P_0 = \text{diag}(100, 1)$.

2.1 Récapitulatif de l'EKF

$$\begin{aligned}
\text{Prédiction : } \hat{x}_{k|k-1} &= f(\hat{x}_{k-1|k-1}), & P_{k|k-1} &= F P_{k-1|k-1} F^\top + Q \\
\text{Innovation : } \nu_k &= z_k - h(\hat{x}_{k|k-1}), & S_k &= H P_{k|k-1} H^\top + R \\
\text{Gain : } K_k &= P_{k|k-1} H^\top S_k^{-1} \\
\text{Correction : } \hat{x}_{k|k} &= \hat{x}_{k|k-1} + K_k \nu_k, & P_{k|k} &= (I - K_k H) P_{k|k-1}
\end{aligned} \tag{7}$$




Figure 2: Estimation de la position et de la vitesse avec une mesure d'angle uniquement (Q0b).

La figure 2 révèle un comportement opposé au cas précédent : l'incertitude, qu'il s'agisse de la position ou de la vitesse, croît avec le temps au lieu de converger. Ainsi, après une phase initiale de convergence, l'estimation diverge peu à peu.

2.2 Explication

Pour comprendre cette divergence, on note la covariance $P_k = \begin{bmatrix} a_k & b_k \\ b_k & c_k \end{bmatrix}$, avec $a_k = \text{var}(s_k)$, $c_k = \text{var}(v_k)$ (variance de vitesse) et $b_k = \text{cov}(s_k, v_k)$.

Prédiction ($P_{k|k-1} = F P_{k-1} F^\top + Q$, avec $q_p = 10^{-4}$, $q_v = 10^{-2}$) :

$$a_{k|k-1} = a_{k-1} + 2b_{k-1} + c_{k-1} + q_p, \quad b_{k|k-1} = b_{k-1} + c_{k-1}, \quad c_{k|k-1} = c_{k-1} + q_v. \tag{8}$$

Correction avec $H = [h_s \ 0]$:

$$S_k = h_s^2 a_{k|k-1} + R, \quad K_k = P_{k|k-1} H^\top S_k^{-1} = \frac{1}{S_k} \begin{bmatrix} h_s a_{k|k-1} \\ h_s b_{k|k-1} \end{bmatrix}. \tag{9}$$

Le bloc (2, 2) de $P_k = (I - K_k H) P_{k|k-1}$ donne alors la nouvelle variance de vitesse :

$$c_k = c_{k|k-1} - \frac{h_s^2 b_{k|k-1}^2}{S_k} = c_{k|k-1} - \frac{h_s^2 b_{k|k-1}^2}{h_s^2 a_{k|k-1} + R}. \tag{10}$$

D'où la récurrence complète :

$$c_k = c_{k-1} + q_v - \frac{h_s^2 (b_{k-1} + c_{k-1})^2}{h_s^2 (a_{k-1} + 2b_{k-1} + c_{k-1} + q_p) + R} \quad (11)$$

Lecture de la formule

- Terme $+q_v$: à chaque prédiction, le bruit de dynamique injecte $q_v = 10^{-2}$ d'incertitude sur la vitesse. C'est le moteur de la croissance.
- Terme de correction $-\frac{h_s^2 b_{k|k-1}^2}{S_k}$: c'est la seule chose qui « tire » la variance de vitesse vers le bas. Or la mesure d'angle n'observe pas directement la vitesse (H a une composante nulle sur v) : la vitesse n'est corrigée qu'indirectement, via sa covariance croisée b avec la position.
- Rôle de $h_s \rightarrow 0$: quand l'objet s'éloigne, $h_s = -20/(s^2 + 400) \rightarrow 0$. Alors le numérateur $h_s^2 b_{k|k-1}^2 \rightarrow 0$ (et $S_k \rightarrow R$, non nul), donc le terme de correction s'annule. La récurrence se réduit à

$$c_k \approx c_{k|k-1} = c_{k-1} + q_v. \quad (12)$$

La variance de vitesse croît alors linéairement, avec une pente $q_v = 10^{-2}$.

3 Q1.1 — Localisation GNSS : modèle et trou de mesure

Après avoir traité les problèmes unidimensionnels, on généralise désormais le filtre à un objet qui se déplace dans $\mathbb{R}^3$. Concrètement, on applique la classe `KalmanFilter` à une localisation GNSS (de type GPS) simplifiée : seules les trois coordonnées de position sont mesurées, et l'on suppose ces mesures indépendantes en choisissant un pas de temps ΔT suffisamment grand.

3.1 Modèle

État. L'état regroupe la position et la vitesse :

$$x_k = [p_x \ p_y \ p_z \ v_x \ v_y \ v_z]^\top \in \mathbb{R}^6. \quad (13)$$

Modèle d'évolution. En l'absence de commande, la dynamique est à vitesse quasi-constante :

$$x_{k+1} = F x_k + w_k, \quad w_k \sim \mathcal{N}(0, Q), \quad (14)$$

avec la matrice de transition ($\Delta T = 1$) :

$$F = \begin{bmatrix} 1 & 0 & 0 & \Delta T & 0 & 0 \\ 0 & 1 & 0 & 0 & \Delta T & 0 \\ 0 & 0 & 1 & 0 & 0 & \Delta T \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} I_3 & \Delta T I_3 \\ 0 & I_3 \end{bmatrix}, \quad (15)$$

et la covariance du bruit de dynamique :

$$Q = \text{diag}(10^{-4}, 10^{-4}, 10^{-4}, 10^{-2}, 10^{-2}, 10^{-2}). \quad (16)$$

Précisons le sens de ce choix : le bruit sur la vitesse (10^{-2}) est nettement plus grand que celui sur la position (10^{-4}). En d'autres termes, le modèle « laisse de la latitude » à la vitesse, ce qui lui permet de suivre un objet dont la vitesse réelle n'est pas rigoureusement constante.

Modèle d'observation. On observe les trois coordonnées de position :

$$y_k = H x_k + v_k, \quad v_k \sim \mathcal{N}(0, R), \quad (17)$$

$$H = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix} = [I_3 \quad 0_{3 \times 3}], \quad R = 100 I_3 \quad (\sigma_{\text{mesure}} = 10 \text{ m}). \quad (18)$$

Initialisation. Enfin, l'état vrai initial vaut $x_0^{\text{true}} = [20, -10, 5, 0, 5, 0]^T$. De son côté, le filtre démarre de l'estimation $x_0 = 0_6$, avec la forte incertitude initiale suivante :

$$P_0 = \text{diag}(10^4, 10^4, 10^4, 10^2, 10^2, 10). \quad (19)$$

3.2 Trou de mesure

On introduit à présent un trou de mesure : la mesure est supprimée entre $t = 10$ et $t = 20$ (exclus), au moyen du masque `has_measure[11:21] = False`. Pendant cette fenêtre, la boucle saute les étapes de simulation et de correction, de sorte que seules les prédictions sont exécutées, si bien que

$$\hat{x}_{k+1} = \hat{x}_{k+1|k} = F \hat{x}_k, \quad P_{k+1} = P_{k+1|k} = F P_k F^T + Q. \quad (20)$$




Figure 3: Localisation GNSS avec un trou de mesure entre $t = 10$ et $t = 20$.

La figure 3 montre que, pendant le trou, l'incertitude sur la position augmente nettement, tandis que celle sur la vitesse reste quasi constante. Autrement dit, privé de mesure, le filtre se contente d'extrapoler à partir de son modèle de mouvement : la covariance P n'étant plus recadrée, elle ne peut que croître.

3.3 Explication

On observe ainsi, sur les bandes $\pm 3\sigma$, que la variance de position croît tandis que la variance de vitesse reste quasi constante. On le justifie à présent par un calcul exact, mené avec la matrice F complète (6×6).

Écriture par blocs. On note l'état $x = [p \ v]^\top$, où $p = [p_x \ p_y \ p_z]^\top$ désigne la position et $v = [v_x \ v_y \ v_z]^\top$ la vitesse. Avec $\Delta T = 1$:

$$F = \begin{bmatrix} I_3 & I_3 \\ 0_3 & I_3 \end{bmatrix}, \quad Q = \begin{bmatrix} q_p I_3 & 0_3 \\ 0_3 & q_v I_3 \end{bmatrix}, \quad q_p = 10^{-4}, \quad q_v = 10^{-2}. \quad (21)$$

De la même manière, on partitionne la covariance complète :

$$P_k = \begin{bmatrix} P_{pp,k} & P_{pv,k} \\ P_{vp,k} & P_{vv,k} \end{bmatrix}, \quad (22)$$

où $P_{pp,k}$ est la variance de position (3×3), $P_{vv,k}$ celle de vitesse, et $P_{pv,k} = P_{vp,k}^\top$ la covariance croisée position-vitesse.

Pendant le trou, on a une prédiction seule : $P_{k+1} = F P_k F^\top + Q$. Le produit $F P_k F^\top$ donne :

$$F P_k F^\top = \begin{bmatrix} P_{pp,k} + P_{pv,k} + P_{vp,k} + P_{vv,k} & P_{pv,k} + P_{vv,k} \\ P_{vp,k} + P_{vv,k} & P_{vv,k} \end{bmatrix}, \quad (23)$$

d'où les récurrences par blocs :

$$\boxed{\begin{aligned} P_{pp,k+1} &= P_{pp,k} + P_{pv,k} + P_{vp,k} + P_{vv,k} + q_p I_3 \\ P_{pv,k+1} &= P_{pv,k} + P_{vv,k} \\ P_{vp,k+1} &= P_{vp,k} + P_{vv,k} \\ P_{vv,k+1} &= P_{vv,k} + q_v I_3. \end{aligned}} \quad (24)$$

Découplage par axe. Puisque F , Q , H et R sont diagonales par blocs (un bloc 2×2 par axe), tous les blocs P_{pp} , P_{pv} , P_{vp} , P_{vv} sont eux-mêmes diagonaux. Chaque axe (x, y, z) suit donc une récurrence scalaire indépendante ; ainsi, pour un axe donné, en posant

$$a_k = (P_{pp,k})_{ii}, \quad b_k = (P_{pv,k})_{ii} = (P_{vp,k})_{ii}, \quad c_k = (P_{vv,k})_{ii}, \quad (25)$$

les récurrences par blocs se réduisent exactement à :

$$\boxed{\begin{aligned} a_{k+1} &= a_k + 2b_k + c_k + q_p \\ b_{k+1} &= b_k + c_k \\ c_{k+1} &= c_k + q_v. \end{aligned}} \quad (26)$$

Variance de vitesse : croissance linéaire, pente faible. La troisième récurrence donne immédiatement

$$c_k = c_0 + k q_v. \quad (27)$$

La variance de vitesse croît donc linéairement en k , avec une pente $q_v = 10^{-2}$ très faible. Sur 10 pas, $c_{10} - c_0 = 0.1$, à comparer à $c_0 \approx 0.14$ (régime stationnaire) : l'écart-type $\sigma_v(k) = \sqrt{c_0 + k q_v}$ varie peu, ce qui explique que la bande $\pm 3\sigma_v$ semble constante.

Variance de position : croissance quadratique. De $b_{k+1} = b_k + c_k$, on déduit

$$b_k = b_0 + k c_0 + q_v \frac{k(k-1)}{2}. \quad (28)$$

En injectant dans la récurrence de a puis en sommant, on obtient la forme fermée :

$$a_k = a_0 + (2b_0 + c_0 + q_p) k + c_0 k(k-1) + q_v \frac{k(k-1)(2k-1)}{6} \quad (29)$$

Le terme dominant est quadratique : $a_k \sim c_0 k^2$ (le terme cubique en q_v est négligeable devant lui). En effet, la dérivée seconde discrète

$$\Delta^2 a_k = \Delta a_{k+1} - \Delta a_k = 2c_k + q_v = 2c_0 + q_v + 2q_v k \approx 2c_0 \quad (30)$$

est constante au premier ordre : c'est la signature d'une croissance quadratique. L'écart-type, lui, croît linéairement : $\sigma_p(k) = \sqrt{a_k} \sim \sqrt{c_0} k$.

Conclusion. C'est donc bien l'écart-type σ (la grandeur tracée) qui est linéaire pour la position et quasi constant pour la vitesse. En termes de variance, la position est quadratique en k (terme dominant $c_0 k^2$), tandis que la vitesse est linéaire, mais avec une pente q_v si faible qu'elle paraît constante.

3.4 Interprétation

Ce comportement a une lecture physique directe. D'une part, la vitesse se propage par simple ajout de bruit ($+q_v$ à chaque pas) : sa variance augmente donc d'une constante à chaque pas, de façon régulière. D'autre part, la position intègre la vitesse ($p_{k+1} = p_k + v_k$) : son incertitude s'accumule, car chaque pas ajoute l'incertitude de vitesse déjà accumulée, d'où la croissance accélérée (quadratique) de sa variance.

Il s'agit là du comportement typique de la navigation à l'estime (dead reckoning) sans recalage externe : privé de mesure, le filtre « navigue à l'aveugle », et ses erreurs ne font que s'additionner d'un pas à l'autre sans jamais être remises à zéro. Dès la reprise des mesures, l'innovation est grande et la covariance élevée : le gain K redevient alors important, le filtre recale brutalement l'estimation, puis P redescend vers son régime stationnaire.

4 Q1.2 — Influence du bruit de dynamique Q

Dans cette expérience, nous étudions l'influence de la matrice Q , qui représente le bruit associé au modèle dynamique. La covariance prédite est donnée par :

$$P_{k|k-1} = F P_{k-1|k-1} F^T + Q. \quad (31)$$

Initialement,

$$Q_{\text{initial}} = \text{diag}(10^{-4}, 10^{-4}, 10^{-4}, 10^{-2}, 10^{-2}, 10^{-2}). \quad (32)$$

Nous avons ensuite augmenté Q d'un facteur 100 :

$$Q_{\text{nouveau}} = 100 Q_{\text{initial}} = \text{diag}(10^{-2}, 10^{-2}, 10^{-2}, 1, 1, 1). \quad (33)$$




Figure 4: Influence de l'augmentation du bruit de dynamique Q .

On observe que l'augmentation de Q élargit les bandes d'incertitude, car la covariance prédite augmente :

$$Q \uparrow \implies P_{k|k-1} \uparrow \implies \sigma \uparrow.$$

L'effet est particulièrement visible sur les vitesses v_x , v_y et v_z . En effet, les mesures GNSS observent directement la position mais pas la vitesse :

$$H = [I_3 \ 0_3]. \quad (34)$$

Les positions sont donc régulièrement corrigées par les mesures, tandis que les vitesses sont estimées indirectement à partir du modèle dynamique. Elles sont ainsi plus sensibles à l'augmentation du bruit de processus Q . L'information de position permet néanmoins de corriger indirectement les vitesses grâce au couplage entre position et vitesse dans la matrice F .

5 Q1.3 — Influence du bruit de mesure R

Dans cette expérience, on fait varier la matrice R , qui représente le bruit associé aux mesures GNSS.

La covariance de l'innovation est donnée par :

$$S_k = HP_{k|k-1}H^T + R. \quad (35)$$

Le gain de Kalman est :

$$K_k = P_{k|k-1}H^T (HP_{k|k-1}H^T + R)^{-1}. \quad (36)$$

Lorsque R augmente, S_k augmente et le gain de Kalman K_k diminue. Le filtre accorde donc moins de confiance aux mesures GNSS et davantage à la prédiction issue du modèle dynamique.




Figure 5: Influence de la variation du bruit de mesure R sur l'estimation et l'incertitude du filtre.

On observe que l'augmentation de R entraîne une augmentation des bandes d'incertitude, à la fois pour les positions et pour les vitesses. En effet, la covariance après correction est moins réduite lorsque le gain de Kalman diminue :

$$P_{k|k} = (I - K_k H) P_{k|k-1}. \quad (37)$$

Les positions sont directement mesurées par le GNSS, mais lorsque R est grand, ces mesures sont considérées comme peu fiables et corrigent moins efficacement la prédiction. La position reste donc plus incertaine.

Les vitesses ne sont pas mesurées directement. Elles dépendent de l'information de position pour être corrigées indirectement. Lorsque les mesures de position deviennent moins fiables à cause de l'augmentation de R , cette correction indirecte des vitesses devient également moins efficace. L'incertitude augmente donc aussi pour v_x , v_y et v_z .

Ainsi, contrairement à Q , qui augmente directement l'incertitude lors de la prédiction, une augmentation de R réduit l'efficacité de l'étape de correction. Dans les deux cas, l'incertitude finale du filtre augmente, mais pour des raisons différentes.

6 Q2.1 — Localisation par odométrie : modèle et jacobien

On s'intéresse désormais à la localisation d'un robot à l'aide d'un EKF (fichier `tp1_part2_EKFLocalization.py`). Le robot se déplace dans un plan contenant des amers, c'est-à-dire des points de repère, et se localise à l'aide de deux informations : la distance et la direction (cap) vers un amer.

6.1 Modèle

6.1.1 État

L'état regroupe la position et le cap du robot dans le repère global :

$$x_t = [x_t \ y_t \ \theta_t]^\top \in \mathbb{R}^3. \quad (38)$$

6.1.2 Modèle d'évolution (odométrie)

Le déplacement entre t et $t+1$ est mesuré par odométrie, sous la forme d'un vecteur de déplacement local, exprimé dans le repère du robot à l'instant t :

$$u_t = [x_u \ y_u \ \theta_u]^\top. \quad (39)$$

Le modèle d'évolution est une composition de poses (voir `tcomp`) :

$$x_{t+1} = f(x_t, u_t) = \begin{bmatrix} x_t + x_u \cos \theta_t - y_u \sin \theta_t \\ y_t + x_u \sin \theta_t + y_u \cos \theta_t \\ \theta_t + \theta_u \end{bmatrix}. \quad (40)$$

L'odométrie est bruitée : $u_t = u_t^* + w_t$, avec $w_t \sim \mathcal{N}(0, Q)$. Le bruit porte donc sur la commande u , et non directement sur l'état : il s'agit d'un bruit non additif sur l'état.

Dans le simulateur, la commande vraie est quasi-constante : $u^* = [0, 0.025, \frac{0.1\pi}{180} \sin(\cdot)]^\top$, c'est-à-dire une avance rectiligne assortie d'un léger lacet sinusoïdal.

6.1.3 Modèle d'observation (amers)

On observe la distance et le cap d'un amer de position connue (x_k, y_k) :

$$y_t = h(x_t) = \begin{bmatrix} r_t \\ \varphi_t \end{bmatrix} = \begin{bmatrix} \sqrt{(x_k - x_t)^2 + (y_k - y_t)^2} \\ \text{atan2}(y_k - y_t, x_k - x_t) - \theta_t \end{bmatrix}, \quad (41)$$

bruitée par $v_t \sim \mathcal{N}(0, P_Y)$.

6.1.4 Jacobiennes

$A(x, u) = \partial f / \partial x$ (dérivée par rapport à l'état) :

$$A(x, u) = \begin{bmatrix} 1 & 0 & -x_u \sin \theta - y_u \cos \theta \\ 0 & 1 & x_u \cos \theta - y_u \sin \theta \\ 0 & 0 & 1 \end{bmatrix}. \quad (42)$$

$B(x, u) = \partial f / \partial u$ (dérivée par rapport à la commande) :

$$B(x, u) = \begin{bmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} R(\theta) & 0 \\ 0 & 1 \end{bmatrix}. \quad (43)$$

$H(x) = \partial h / \partial x$, avec $dx = x_k - x$, $dy = y_k - y$ et $r = \sqrt{dx^2 + dy^2}$:

$$H(x) = \begin{bmatrix} -\frac{dx}{r} & -\frac{dy}{r} & 0 \\ \frac{dy}{r^2} & -\frac{dx}{r^2} & -1 \end{bmatrix}. \quad (44)$$

6.2 Récapitulatif de l'EKF

Prédiction. Elle utilise l'odométrie u_k et les jacobienues évaluées en $\hat{x}_{k|k}$:

$$\hat{x}_{k+1|k} = f(\hat{x}_{k|k}, u_k), \quad (45)$$

$$P_{k+1|k} = A_k P_{k|k} A_k^\top + B_k Q B_k^\top, \quad (46)$$

avec $A_k = A(\hat{x}_{k|k}, u_k)$ et $B_k = B(\hat{x}_{k|k}, u_k)$.

Correction. Elle n'est exécutée que si une mesure y_{k+1} est disponible :

$$\begin{aligned} S_{k+1} &= H_k P_{k+1|k} H_k^\top + P_Y \\ W_{k+1} &= P_{k+1|k} H_k^\top S_{k+1}^{-1} \\ \hat{x}_{k+1|k+1} &= \hat{x}_{k+1|k} + W_{k+1} (y_{k+1} - h(\hat{x}_{k+1|k})) \\ P_{k+1|k+1} &= P_{k+1|k} - W_{k+1} H_k P_{k+1|k}. \end{aligned} \quad (47)$$

Le cap de $\hat{x}$ et l'innovation angulaire sont en outre ramenés dans $[-\pi, \pi]$ via `angle_wrap`.

7 Q2.2 — Défaillance capteur

L'énoncé (Q2) demande d'implémenter une défaillance capteur : pendant une durée donnée, `get_observation(k)` renvoie `z = None` (aucune mesure). Dans le code fourni :

```
def get_observation(k):
    global Map, xTrue, PYTrue
    if k > 2500 and k < 3500:      # <- défaillance capteur
        return [None, None]
    ...
```

Pendant cette plage (environ 1000 pas), le filtre ne reçoit donc plus aucune observation et n'exécute que la phase de prédiction. Cette question est l'analogie, pour l'EKF de localisation, du « trou de mesure » de la question Q1 GNSS.

Pour $k \in (2500, 3500)$, `get_observation` renvoie `[None, None]`. La boucle principale bascule alors dans la branche `else`, si bien que seule la prédiction est exécutée. Pendant la rupture, on a donc :

$$\begin{aligned} \hat{x}_{k+1} &= \hat{x}_{k+1|k} = f(\hat{x}_k, u_k) \\ P_{k+1} &= P_{k+1|k} = A_k P_k A_k^\top + B_k Q B_k^\top. \end{aligned}$$

(48)

Ce que l'on observe :

- Dérive de l'estimation. Sans recadrage par les amers, le filtre intègre uniquement l'odométrie bruitée. Les erreurs d'odométrie (translation 0.01 et rotation 1°) s'accumulent ainsi à chaque pas : la trajectoire estimée (rouge) s'éloigne de plus en plus de la trajectoire vraie (noire), en suivant la trajectoire odométrique (verte), elle-même en dérive.
- Croissance de la covariance. Chaque pas ajoute $B_k Q B_k^\top$ (bruit d'odométrie propagé) et transfère l'incertitude de cap vers l'incertitude de position via $A_k P A_k^\top$. La covariance ne peut donc que croître, sans jamais être réduite : l'ellipse d'incertitude et les bandes $\pm 3\sigma$ s'élargissent tout au long de la rupture.
- Reconvergence à la reprise. Dès $k \geq 3500$, la première observation d'amer produit une innovation importante et une covariance élevée : le gain W devient grand, le filtre recalcule brutalement l'estimation, puis P retombe vers son régime stationnaire.

7.1 Preuve : croissance de la covariance pendant la rupture

On part de la récurrence de prédiction $P_{k+1} = A_k P_k A_k^\top + B_k Q B_k^\top$ et on l'analyse par blocs.

Bruit d'odométrie isotrope. Les covariances de commande sont $Q = \text{diag}(q_x, q_y, q_\theta)$ avec $q_x = q_y = q$ (même bruit en x_u et y_u). Comme $B = \text{diag}(R(\theta), 1)$ est une rotation du plan augmentée, on a

$$B Q B^\top = \text{diag}(q, q, q_\theta), \quad (49)$$

indépendant de θ : chaque pas de prédiction injecte donc la matrice diagonale $\text{diag}(q, q, q_\theta)$ dans la covariance.

Écriture par blocs. On note $\theta = \theta_k$ et $u = [x_u, y_u, \theta_u]^\top$. La jacobienne A s'écrit

$$A_k = \begin{bmatrix} I_2 & a_k \\ 0 & 1 \end{bmatrix}, \quad a_k = \begin{bmatrix} -x_u \sin \theta - y_u \cos \theta \\ x_u \cos \theta - y_u \sin \theta \end{bmatrix}, \quad (50)$$

où a_k est le vecteur $\partial(\text{position})/\partial\theta$, de module $\|a_k\| = \sqrt{x_u^2 + y_u^2} = v$ (la longueur du pas). Avec la commande nominale $x_u = 0$, $y_u = v$, on a $a_k = -v [\cos \theta, \sin \theta]^\top$.

On partitionne la covariance :

$$P_k = \begin{bmatrix} P_{pp,k} & P_{p\theta,k} \\ P_{p\theta,k}^\top & P_{\theta\theta,k} \end{bmatrix}, \quad P_{pp,k} \in \mathbb{R}^{2 \times 2}, \quad P_{\theta\theta,k} \in \mathbb{R}, \quad P_{p\theta,k} \in \mathbb{R}^2. \quad (51)$$

Le produit $A_k P_k A_k^\top$ donne :

$$A_k P_k A_k^\top = \begin{bmatrix} P_{pp} + a P_{p\theta}^\top + P_{p\theta} a^\top + a a^\top P_{\theta\theta} & P_{p\theta} + a P_{\theta\theta} \\ P_{p\theta}^\top + P_{\theta\theta} a^\top & P_{\theta\theta} \end{bmatrix}, \quad (52)$$

d'où les récurrences par blocs, en ajoutant le bruit $B Q B^\top$:

$$\boxed{\begin{aligned} P_{\theta\theta,k+1} &= P_{\theta\theta,k} + q_\theta \\ P_{p\theta,k+1} &= P_{p\theta,k} + a_k P_{\theta\theta,k} \\ P_{pp,k+1} &= P_{pp,k} + a_k P_{p\theta,k}^\top + P_{p\theta,k} a_k^\top + a_k a_k^\top P_{\theta\theta,k} + q I_2. \end{aligned}} \quad (53)$$

Variance de cap : croissance linéaire. La première récurrence se résout immédiatement :

$$P_{\theta\theta,k} = P_{\theta\theta,0} + k q_\theta. \quad (54)$$

L'incertitude de cap croît donc linéairement (c'est une marche aléatoire), soit un écart-type $\sigma_\theta(k) \sim \sqrt{k q_\theta}$.

Variance de position : croissance super-linéaire (cubique).

Tout d'abord, la covariance croisée s'accumule : de $P_{p\theta,k+1} = P_{p\theta,k} + a_k P_{\theta\theta,k}$, on déduit, pour $a_k \approx a$ quasi constant,

$$P_{p\theta,k} \approx \frac{1}{2} a q_\theta k^2, \quad (55)$$

dont le terme dominant est quadratique, car $P_{\theta\theta,j} \sim q_\theta j$.

Ensuite, en injectant dans la récurrence de P_{pp} , il vient

$$P_{pp,k+1} - P_{pp,k} \approx a a^\top q_\theta k^2 + a a^\top q_\theta k + q I_2. \quad (56)$$

En sommant ($\sum j^2 \sim k^3/3$), le terme dominant est cubique :

$$\boxed{P_{pp,k} \sim \frac{1}{3} a a^\top q_\theta k^3 = \frac{1}{3} v^2 q_\theta k^3 \cdot \begin{bmatrix} \cos^2 \theta & \cos \theta \sin \theta \\ \cos \theta \sin \theta & \sin^2 \theta \end{bmatrix}} \quad (57)$$

L'écart-type de position croît donc comme

$$\sigma_p(k) \sim \sqrt{\frac{1}{3}} v \sqrt{q_\theta} k^{3/2}. \quad (58)$$

Conclusion. Pendant la rupture, le cap voit sa variance croître linéairement en k (ajout d'un bruit constant q_θ par pas), tandis que la position voit la sienne croître cubiquement, dominée par le transfert de l'incertitude de cap dans la position ($aa^\top P_{\theta\theta}$), avec le facteur de pas v^2 .

On peut noter un contraste avec Q1 (GNSS) : dans Q1, le bruit était additif sur l'état ($FPF^\top + Q$) et la position croissait quadratiquement (intégration de la vitesse). Ici, en revanche, le bruit porte sur la commande ($BQB^\top$), et c'est l'incertitude de cap qui, en s'intégrant dans la position via l'odométrie, fait croître la variance de position en k^3 : c'est la signature typique de la navigation à l'estime (dead reckoning).

7.2 Interprétation

Le robot navigue à l'aveugle. Tant qu'il voit des amers, chaque mesure le « recale » : elle lui redonne sa position vraie et écrase l'erreur accumulée. Pendant la défaillance, au contraire, il ne lui reste que son odométrie : il avance « au compteur », en accumulant à chaque pas une petite erreur, sans jamais pouvoir la corriger.

8 Q2.3 — Erreurs de modèle

Dans cette question, on étudie l'influence d'une mauvaise estimation des bruits utilisés par le filtre. Les matrices Q_{True} et P_Y^{True} correspondent aux bruits réellement utilisés dans le simulateur, tandis que Q_{Est} et P_Y^{Est} sont ceux supposés par le filtre.

Lorsque le bruit d'odométrie est fortement surestimé et que le bruit des observations est sous-estimé, on utilise par exemple :

$$Q_{\text{Est}} = 100Q_{\text{True}}, \quad P_Y^{\text{Est}} = 0.1P_Y^{\text{True}}.$$

Le filtre considère alors que l'odométrie est très bruitée et accorde donc moins de confiance à la prédiction. À l'inverse, il considère les observations comme très précises et leur donne davantage de poids lors de la correction.




Figure 6: Influence d'une forte surestimation du bruit d'odométrie et d'une sous-estimation du bruit des observations.

On observe que l'estimation reste globalement proche de la trajectoire réelle. Cependant, les erreurs et les incertitudes sont particulièrement visibles sur l'orientation θ . Cette situation montre que le filtre fait fortement confiance aux observations pour corriger la prédiction, car le bruit de mesure utilisé par le filtre est considéré comme faible.

Nous considérons ensuite le cas demandé dans l'énoncé où le bruit estimé sur la distance des landmarks est important, tandis que le bruit sur leur direction reste correct. On utilise :

$$P_Y^{\text{Est}} = \text{diag} \left(100^2, \left(\frac{6\pi}{180} \right)^2 \right).$$

Le filtre considère alors les mesures de distance comme peu fiables et leur attribue un poids plus faible. En revanche, les mesures de direction restent considérées comme fiables et conservent une influence importante dans la correction.




Figure 7: Estimation lorsque le bruit estimé sur la distance des landmarks est important tandis que le bruit sur leur direction reste correct.

On observe que la trajectoire estimée reste proche de la trajectoire réelle malgré la forte incertitude sur les distances. Les informations angulaires permettent en effet de continuer à corriger l'estimation, notamment l'orientation. La distance n'est pas supprimée de l'observation, mais son influence dans la correction est fortement réduite.

Ainsi, une mauvaise estimation des matrices de covariance modifie directement le compromis entre la prédiction et les observations. Le filtre accorde plus ou moins de confiance à chaque source d'information en fonction des valeurs de Q_{Est} et P_Y^{Est} .

9 Q2.4 — Observabilité partielle

Dans cette expérience, on étudie le comportement de l'EKF lorsque seule une partie de l'observation des landmarks est disponible. On considère successivement le cas où seule la distance est utilisée, puis celui où seule la direction est utilisée.




Figure 8: Estimation avec uniquement la distance aux landmarks.

Lorsque seule la distance est utilisée, l'observation est donnée par :

$$z = r = \sqrt{(x_L - x)^2 + (y_L - y)^2}.$$

La distance fournit une information sur la position du robot par rapport aux landmarks, mais elle ne dépend pas directement de son orientation θ . Sur la figure, on observe néanmoins que l'estimation de la trajectoire reste proche de la trajectoire réelle et que les erreurs sur x et y restent faibles.

En revanche, l'incertitude sur θ est plus importante. L'orientation est donc moins directement observable avec la distance seule et doit être estimée en partie grâce au modèle dynamique et aux observations successives.




Figure 9: Estimation avec uniquement la direction des landmarks.

Dans le second cas, seule la direction du landmark est utilisée :

$$z = \theta_L - \theta.$$

Cette observation contient directement une information sur l'orientation du robot. La figure montre que la trajectoire estimée reste également proche de la trajectoire réelle et que les erreurs sur x et y restent faibles.

L'effet est particulièrement visible sur θ : la bande d'incertitude 3σ est nettement plus faible que dans le cas de la distance seule. L'orientation est donc mieux contrainte lorsque la direction du landmark est mesurée directement.

Ainsi, la distance et la direction fournissent des informations complémentaires : la distance contraint principalement la position, tandis que la direction apporte davantage d'information sur l'orientation. Dans les deux cas, l'EKF reste capable de suivre la trajectoire, mais avec une incertitude différente selon la composante observée.

Conclusion

Au fil de ce rapport, le filtre de Kalman s'est révélé un outil efficace pour la localisation, mais avec des limites bien identifiées. Le filtre linéaire converge rapidement, alors que l'EKF, privé d'une information suffisante (mesure d'angle seule), peut diverger. Les trous de mesure font croître l'incertitude – quadratiquement pour la position en GNSS, cubiquement dans le cas de l'odométrie – jusqu'au retour des observations. Enfin, le réglage des covariances Q et R conditionne directement le compromis entre confiance accordée au modèle et confiance accordée aux mesures : un mauvais choix dégrade sensiblement l'estimation.